

ESTUDO DE BIBLIOTECAS

Dask

Processamento paralelo de dados em Python

Big Data

Paralelismo

Lazy Eval

Open Source

O que é Dask?

"Dask processa dados maiores que a RAM com a mesma API do Pandas —de forma paralela e particionada."



Out-of-core

Divide os dados em partes
e processa sem travar a RAM



Paralelo

Usa todos os núcleos
automaticamente



API do Pandas

Mesmas funções —
mudança mínima no código



Regra prática: dados que cabem na RAM → Pandas. Dados grandes ou múltiplos servidores → Dask.

Experimento — Volumes pequenos

PEQUENO - 1 MB

0.09s

Pandas

0.14s


Dask

Pandas 1.6x mais rápido

O Dask gasta tempo montando o grafo antes de começar a processar.

Pandas x Dask — 29,075 linhas (1 MB)

Tempo de execução



Fator de velocidade

1.6x

Pandas mais rápido

MÉDIO - 84 MB

2.49s

Pandas

1.91s


Dask

Dask 1.3x mais rápido

Ponto de virada: o paralelismo começa a compensar o overhead.

Pandas x Dask — 2,910,232 linhas (84 MB)

Tempo de execução



Fator de velocidade

1.3x

Dask mais rápido

Experimento — Volume grande (325 MB | 11,6M linhas)

9.92s

Pandas

8.55s

Dask

Dask


Vencedor

1.2x

Diferença

Pandas x Dask — 11,640,048 linhas (336 MB)

Tempo de execução



Fator de velocidade

1.2x

Dask mais rápido



Dask dividiu os 12M de linhas entre os núcleos do processador em paralelo. Pandas percorreu tudo em sequência.

Experimento —Dados complexos (321 MB | 15 colunas | 5 agregações)

7.70s

Pandas

19.14s

Dask

Pandas


Vencedor

2.5×

Diferença

Pandas x Dask — 3,267,957 linhas (324 MB)

Tempo de execução



Fator de velocidade

2.5×

Pandas mais rápido



5 agregações = 5×.compute() = Dask relê o disco 5 vezes. Pandas carregou tudo na RAM uma vez e reutilizou. Mais operações independentes -> favor Pandas.

Resumo —os 4 cenários

Cenário	Pandas	Dask	Vencedor
Pequeno (8 MB)	0.09s	0.14s	Pandas 1.6×
Médio (81 MB)	2.49s	1.91s	Dask 1.3×
Grande (325 MB)	9.92s	8.55s	Dask 1.2×
Complexo (321 MB)	7.70s	19.14s	Pandas 2.5×



Não é competição —são ferramentas complementares. Dask brilha no volume; Pandas brilha na complexidade numa só máquina.

Dask é a escolha certa na hora certa



Dados < RAM
→ Use Pandas



Dados > 100 MB simples
→ Dask começa a valer



Dados grandes
→ Dask 2–4×mais rápido



Dados > RAM
→ Apenas Dask funciona

```
pip install "dask[dataframe]"
```